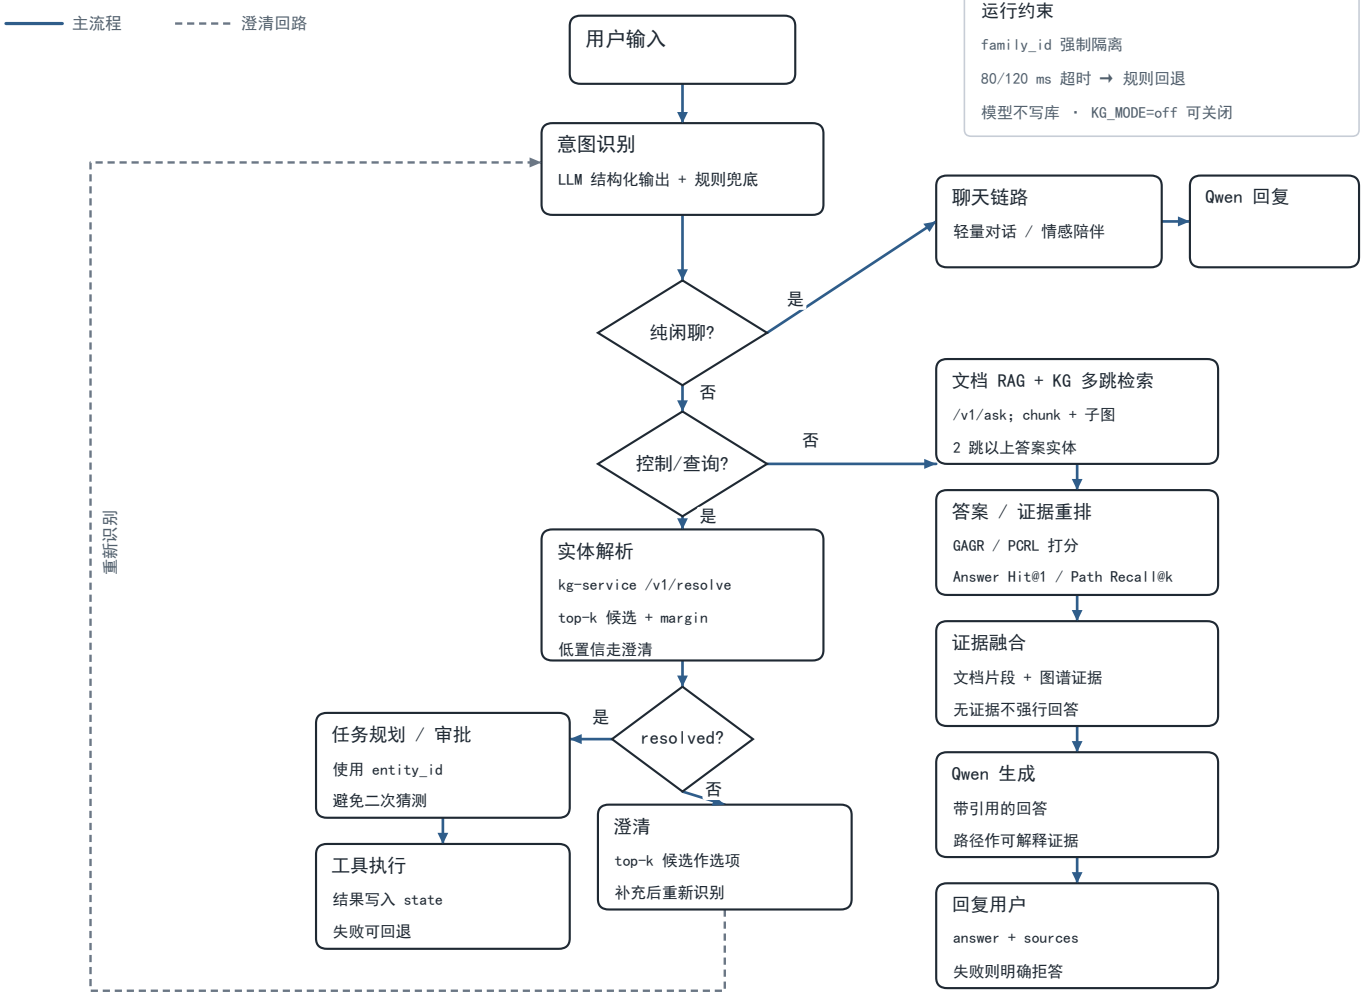
主流程
澄清回路
运行约束
family_id 强制隔离
80/120 ms 超时 → 规则回退
模型不写库 · KG_MODE=off 可关闭
用户输入
意图识别
LLM 结构化输出 + 规则兜底
聊天链路
轻量对话 / 情感陪伴
Qwen 回复
是
纯闲聊?
否
文档 RAG + KG 多跳检索
/v1/ask; chunk + 子图
2 跳以上答案实体
否
控制/查询?
是
答案 / 证据重排
GAGR / PCRL 打分
Answer Hit@1 / Path Recall@k
实体解析
kg-service /v1/resolve
top-k 候选 + margin
低置信走澄清
证据融合
文档片段 + 图谱证据
无证据不强行回答
是
resolved?
否
Qwen 生成
带引用的回答
路径作可解释证据
任务规划 / 审批
使用 entity_id
避免二次猜测
澄清
top-k 候选作选项
补充后重新识别
回复用户
answer + sources
失败则明确拒答
工具执行
结果写入 state
失败可回退
重新识别